3. Übungsblatt (Ereignisdatenanalyse)

Daria Tisch

1 Organisation

1.1 Arbeitsverzeichnis festsetzen

```
# set working directory
setwd("C:/Users/ti/Local/seafile/main/teaching/2024_wuppertal/studis/uebungen")
```

1.2 Packages installieren und laden

```
# Packages
pkgs <- c(
  "tidyverse",
  "sjPlot", # nice html tables
  "survival", # survival analysis
  "ggsurvfit" # flexible time-to-event figures
)

## Install uninstalled packages
lapply(pkgs[!(pkgs %in% installed.packages())], install.packages)

## Load all packages to library
lapply(pkgs, library, character.only = TRUE)
```

1.3 Daten einlesen

Wir arbeiten mit einem Datensatz, der Teil des R-Pakets {survival} ist. Bitte lasse Dir alle Datensätze des Pakets anzeigen und speichere den Datensatz lung als *df*.

Datensätze, die im Package survival enthalten sind, anzeigen:

```
data(package = "survival")
```

lung Datensatz als *df* speichern:

```
# Lungenkrebsdatensatz als df speichern
df = lung
```

Schaue Dir nun die Beschreibung des Datensatzes an:

```
?lung
```

```
starte den http Server für die Hilfe fertig
```

Der Datensatz enthält also Informationen zu PatientInnen der North Central Cancer Treatment Group.

2 Datenaufbereitung

In dieser Übung möchten wir untersuchen, ob es Unterschiede zwischen Männern und Frauen in der Überlebenszeit bei Lungenkrebs gibt.

Wir brauchen für unsere Analyse daher die folgenden 3 Variablen:

- dead (0: lebend, 1: tot)
- female (0: männlich, 1: weiblich)
- time (Tage)

Bitte suche diese heraus oder erstelle sie.

```
df <- df %>%
  mutate(
    dead = recode(status, `1` = 0, `2` = 1),
    female = recode(sex, `1` = 0, `2` = 1)
  )
```

3 Datenexploration

3.1 Anzahl Beobachtungen

Wie viele Personen sind in dem Datensatz?

```
length(df$dead)
```

```
[1] 228
```

```
nrow(lung)
```

```
[1] 228
```

3.2 Anzahl Frauen und Männer

Wie viele Frauen und Männer sind jewils in dem Datensatz?

```
table(df$female)
```

```
  0   1
138  90
```

3.3 Anzahl Personden, die im Beobachtungszeitraum gestorben sind

Wie viele Personen sind im Beobachtungszeitraum gestorben?

```
table(df$dead)
```

```
  0   1
 63 165
```

3.4 Kreuztabelle Geschlecht und Überleben

Wie viel Prozent der Frauen und wie viel Prozent der Männer sind im Beobachtungszeitraum gestorben?

```r
df %>%
  group_by(female) %>%
  summarise(
    total = n(),                              # Gesamtanzahl je Geschlecht
    deaths = sum(dead == 1),                 # Anzahl der gestorbenen Personen
    percent_deaths = (deaths / total) * 100  # Prozentsatz der Gestorbenen
  ) %>%
  arrange(female)
```

```
# A tibble: 2 x 4
  female total deaths percent_deaths
   <dbl> <int>  <int>          <dbl>
1      0   138    112           81.2
2      1    90     53           58.9
```

4 Ereignisdatenanalyse

4.1 Zensierung

Wie viele rechtszensierte und wie viele linkszentrierte Beobachtungen liegen vor?

```r
table(df$dead)
```

```
  0   1
 63 165
```

4.2 Erste 10 Fälle

Schauen wir uns die ersten 10 Fälle des Datensatzes an. Was bedeutet das + hinter einer Zahl?

```r
Surv(df$time, df$dead)[1:10]
```

```
 [1]  306   455  1010+  210   883  1022+  310   361   218   166
```

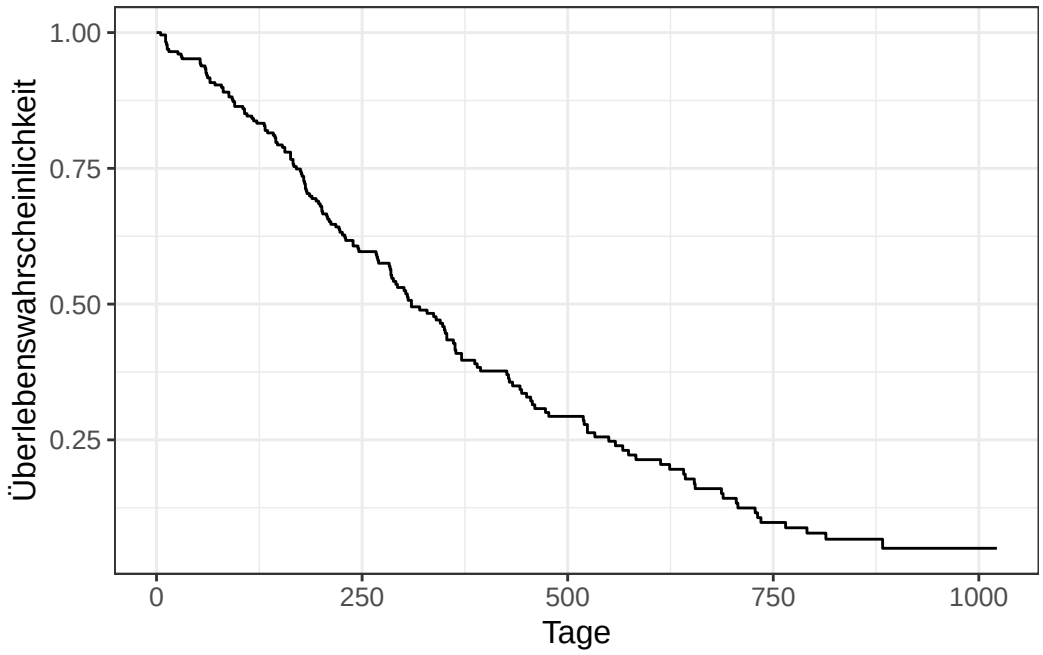
Das + bedeutet, dass es sich um rechtszensierte Fälle handelt. Diese Personen leben zum Ende des Beobachtungszeintraums noch.

Was ist wohl der Nullpunkt der Zeitvariable *time*?

4.3 Kaplan-Meier-Kurve

Erstelle eine Kaplan-Meier-Kurve.

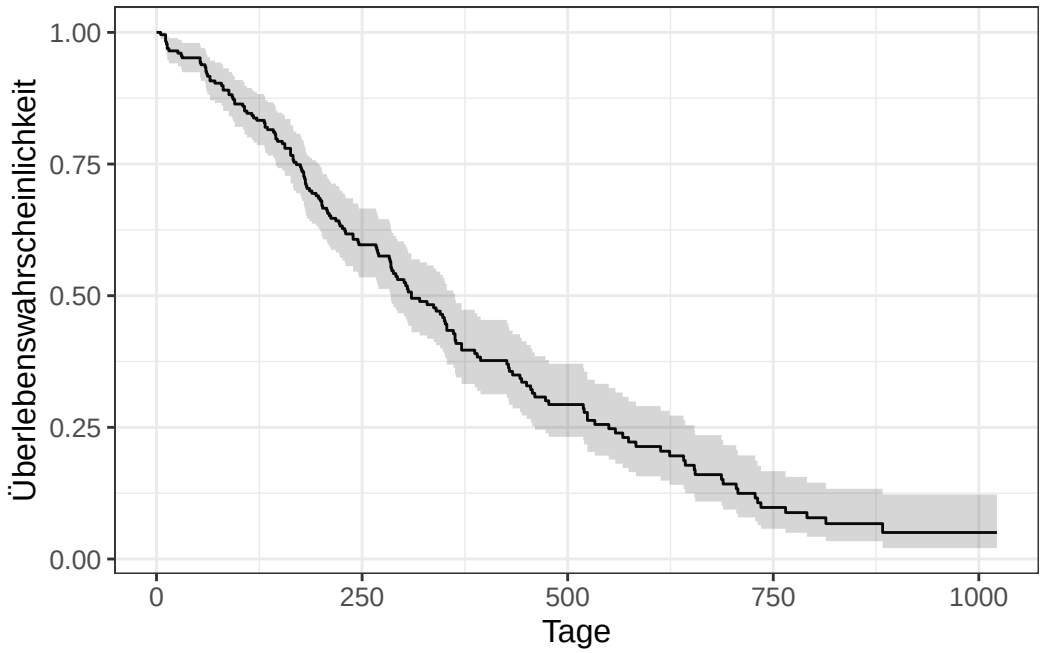
```
survfit2(Surv(time, dead) ~ 1, data = df) %>%
  ggsurvfit() +
  labs(
    x = "Tage",
    y = "Überlebenswahrscheinlichkeit"
  )
```



4.4 Kaplan-Meier-Kurve mit KI

Nun ergänze die Kurve mit einem Konfidenzintervall.

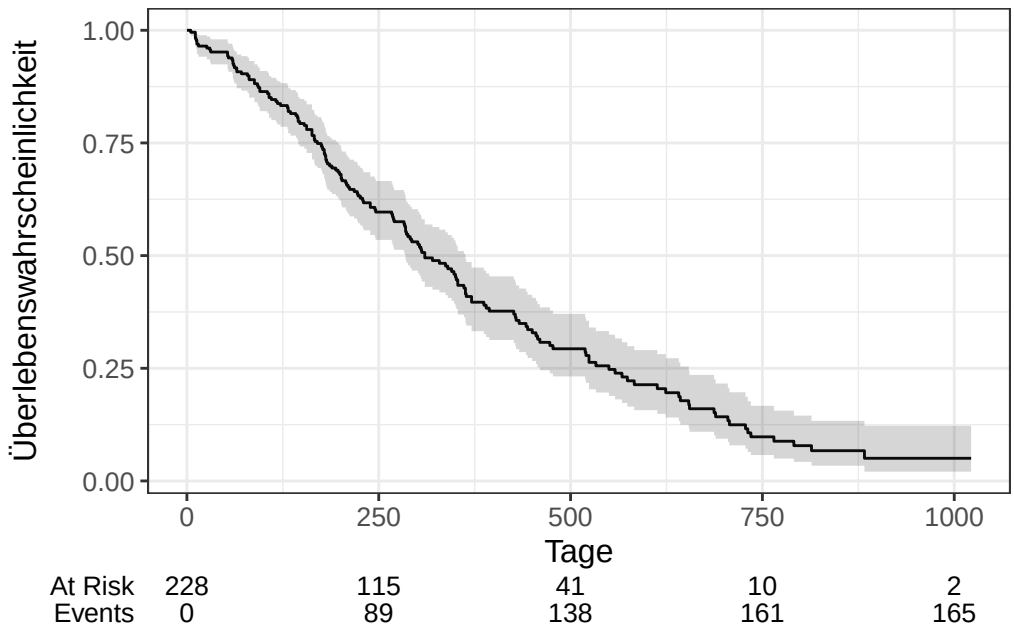
```
survfit2(Surv(time, dead) ~ 1, data = df) %>%
  ggsurvfit() +
  labs(
    x = "Tage",
    y = "Überlebenswahrscheinlichkeit"
  )+
  add_confidence_interval()
```



4.5 Kaplan-Meier-Kurve mit Ki und Risikotabelle

Und nun füge bitte noch eine Risikotabelle hinzu.

```
survfit2(Surv(time, dead) ~ 1, data = df) %>%
  ggsurvfit() +
  labs(
    x = "Tage",
    y = "Überlebenswahrscheinlichkeit"
  )+
  add_confidence_interval() +
  add_risktable()
```



Wie viele Personen leben nach 500 Tagen noch?

4.6 Schätzung der Überlebensrate nach einem Jahr

```
summary(survfit(Surv(time, dead) ~ 1, data = df), times = 365)
```

```
Call: survfit(formula = Surv(time, dead) ~ 1, data = df)

 time n.risk n.event survival std.err lower 95% CI upper 95% CI
  365     65     121    0.409  0.0358        0.345        0.486
```

Wir stellen fest, dass die 1-Jahres-Überlebenswahrscheinlichkeit in dieser Studie 41% beträgt.

5 Überlebenszeit im Median

Wie viele Tage überleben die PatientInnen im Median?

```
survfit(Surv(time, dead) ~ 1, data = df)
```

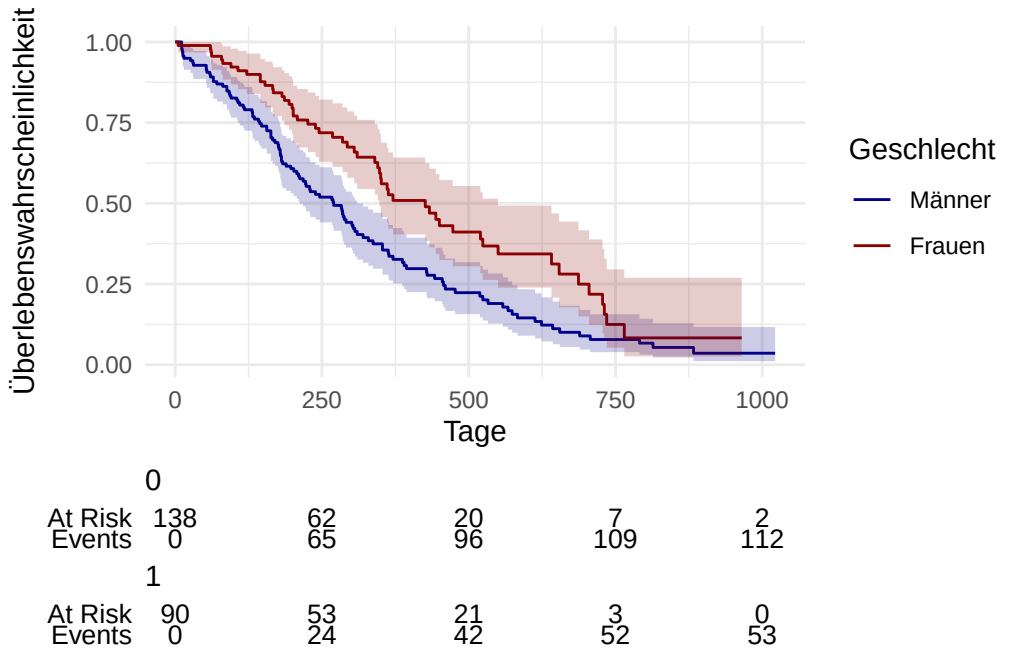
```
Call: survfit(formula = Surv(time, dead) ~ 1, data = df)

       n events median 0.95LCL 0.95UCL
[1,] 228    165    310     285     363
```

6 Kaplan-Meier-Kurve nach Geschlecht

Nun möchten wir die Geschlechterunterschiede in der Überlebenswahrscheinlichkeit über die Zeit graphisch untersuchen.

```
survfit2(Surv(time, dead) ~ female, data = df) %>%
  ggsurvfit() +
  labs(
    x = "Tage",
    y = "Überlebenswahrscheinlichkeit",
    color = "Geschlecht"
  )+
  add_confidence_interval() +
  add_risktable() +
 scale_color_manual(values = c('darkblue', 'darkred'),  labels = c("Männer", "Frauen") ) +
  scale_fill_manual(values = c('darkblue', 'darkred'),  labels = c("Männer", "Frauen") ) +
  theme_minimal() + guides(fill = "none")
```



7 Cox Proportional Hazards Model

Nun schätzen wir ein Cox Proportional Hazards Model. Gibt es signifikante Geschlechterunterschiede? Ist die Proportionalitätsannahme erfüllt?

```
model1 = coxph(Surv(time, dead) ~ female, data = df)
summary(model1)
```

```
Call:
coxph(formula = Surv(time, dead) ~ female, data = df)

  n= 228, number of events= 165

          coef exp(coef) se(coef)      z Pr(>|z|)
female -0.5310    0.5880   0.1672 -3.176  0.00149 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

       exp(coef) exp(-coef) lower .95 upper .95
female     0.588      1.701    0.4237     0.816

Concordance= 0.579  (se = 0.021 )
Likelihood ratio test= 10.63  on 1 df,   p=0.001
Wald test            = 10.09  on 1 df,   p=0.001
Score (logrank) test = 10.33  on 1 df,   p=0.001
```

```
cox.zph(model1)
```

```
       chisq df     p
female  2.86  1 0.091
GLOBAL  2.86  1 0.091
```

Erstelle eine Tabelle zur besseren Übersicht

```
tab_model(model1,
          show.ci = FALSE, p.style = "stars",
          string.se = "se", string.est = "HR",
          string.pred = " ")
```

	Surv(time, dead)
	HR
female	0.59 **
Observations	228
R^2 Nagelkerke	0.046
* p<0.05 ** p<0.01	*** p<0.001

7.1 Interpretiere den Koeffizienten von *female*:

Bei einem Cox-Regressionsmodell interessieren wir uns meist für die Hazard Ratio (HR). Die HR stellt das Verhältnis der Risiken zwischen zwei Gruppen zu einem bestimmten Zeitpunkt dar. Die HR wird als die momentane Rate des Auftretens des interessierenden Ereignisses bei denjenigen interpretiert, die noch ein Risiko für dieses Ereignis haben. Die HR ist exp( ).

- HR < 1: verringertes Sterberisiko
- HR > 1: erhöhtes Sterberisiko

HR = 0,59: Zu einem bestimmten Zeitpunkt sterben 0,59 mal so viele Frauen wie Männer. Frauen haben in dieser Stichprobe ein deutlich geringeres Sterberisiko als Männer.

8 Render

Wandle dieses Dokument in ein PDF und ein HTML Dokument um.

9 Weiterführende Literatur

- R for Data Science
- https://www.emilyzabor.com/tutorials/survival_analysis_in_r_tutorial.html